Accidentes de tráfico en Madrid y meteorología (2019-2024)

Análisis exploratorio, contrastes estadísticos y dashboard

Informe final del proyecto
Octubre de 2026

Repositorio: github.com/miguelffer12/proyecto-final-aemet

Fuentes de datos: Ayuntamiento de Madrid (datos abiertos, accidentes de tráfico) y AEMET OpenData (estación Madrid-Retiro, 3195).

1. Resumen ejecutivo

Este trabajo estudia cómo se relacionan la meteorología, el calendario, la franja horaria y el tipo de vehículo con la frecuencia y la gravedad de los accidentes de tráfico con víctimas en la ciudad de Madrid entre 2019 y 2024. Se cruzan dos fuentes abiertas (115.640 accidentes y 271.250 personas implicadas, y la climatología diaria de la estación de Retiro), se limpian y se analizan con cinco contrastes de hipótesis, y los resultados se presentan en un dashboard de Excel.

Resultados principales

- **La lluvia aumenta algo la frecuencia, pero no la gravedad.** Los días de lluvia tienen un 4,6 % más de accidentes (IRR = 1,046; IC 95 % 1,021-1,073), mientras que el porcentaje de lesiones graves o mortales es casi idéntico con y sin lluvia (2,09 % frente a 2,27 %; V de Cramér = 0,012).
- **El calendario pesa más que el tiempo.** El viernes es el día con más accidentes (mediana de 65 al día) y el domingo el que menos (42); los festivos tienen un 38 % menos de accidentes que un día equivalente (IRR = 0,62).
- **La temperatura apenas importa** una vez controlada la estacionalidad: la correlación bruta ($\rho = -0{,}16$) se reduce a un efecto de +4 % cada 10 °C.
- **El tipo de vehículo es el factor dominante de gravedad.** Frente al turismo, las motos de más de 125 cc multiplican por 25 las probabilidades de lesión grave o mortal, las de hasta 125 cc por 17 y la bicicleta por 14. La madrugada (OR = 2,2) y el alcohol positivo (OR = 1,34) también aumentan el riesgo.
- **Límites importantes:** una única estación meteorológica, lluvia diaria (no horaria), sin datos de tráfico y un 45 % de personas sin lesividad registrada. Los resultados describen asociaciones, no causas.

2. Introducción y objetivo

La pregunta que guía el trabajo es: **¿cómo influyen la lluvia, la temperatura, el calendario y la hora en la frecuencia y en la gravedad de los accidentes con víctimas en Madrid?** Para responderla se formulan cinco hipótesis que se contrastan con un nivel de significación $\alpha = 0{,}05$, y se complementan siempre con el tamaño del efecto y su intervalo de confianza, porque con más de 100.000 observaciones casi cualquier diferencia resulta estadísticamente significativa.

Hipótesis	Enunciado	Prueba
H1	La proporción de lesiones graves o mortales depende de la lluvia.	Chi-cuadrado, V de Cramér
H2	El número de accidentes por día difiere entre días con y sin lluvia.	Mann-Whitney; binomial negativa
H3	El número de accidentes por día difiere según el día de la semana.	Kruskal-Wallis y post-hoc (Bonferroni)
H4	Existe correlación entre temperatura (y precipitación) y accidentes diarios.	Spearman; binomial negativa
H5	La gravedad se asocia con franja horaria, alcohol, sexo y tipo de vehículo, controlando por lluvia.	Regresión logística (errores robustos por accidente)

3. Datos

Fuente	Origen y contenido	Tamaño
A · Accidentes	Ayuntamiento de Madrid, datos abiertos («Accidentes de tráfico de la ciudad de Madrid»). Un registro por persona implicada en accidentes con víctimas atendidos por la Policía Municipal. Seis CSV anuales (2019-2024) con el mismo esquema de 19 columnas.	271.250 filas; 115.640 accidentes distintos (*num_expediente*)

Fuente	Origen y contenido	Tamaño
B · Meteorología	AEMET OpenData, estación Madrid-Retiro (3195), climatología diaria: temperaturas, precipitación, viento y presión. Doce ficheros JSON (la API limita cada petición a seis meses).	2.192 días (20 sin temperatura y 91 sin precipitación)

Las dos fuentes se unen por **fecha** (relación muchos a uno: muchos registros de accidentes por cada día meteorológico), con una validación que comprueba que la unión no pierde ni duplica filas. El dataset final tiene **271.250 filas y 47 columnas**: las 19 originales, el origen de cada fila, la meteorología diaria y las variables derivadas (hora, franja horaria, día de la semana, estación, festivo, lluvia e intensidad, categoría térmica, gravedad y agregados por accidente).

4. Limpieza y preparación

Se auditaron formas, tipos, nulos y esquema de cada año antes de transformar nada. Las decisiones con más impacto en los resultados fueron:

- **Normalización:** nombres de columna y textos sin tildes ni mayúsculas (hay erratas como «LLuvia intensa»), fechas y horas convertidas, y coma decimal a punto. La precipitación inapreciable («Ip») se convierte a 0 con un indicador.
- **Filas idénticas (11.449): se conservan.** El fichero no tiene identificador de persona y suelen ser personas distintas del mismo accidente (varios pasajeros, conductores desconocidos). Eliminarlas habría infravalorado el número de implicados.
- **Lesividad nula (45,2 % de las personas):** se clasifica como «desconocido» y se excluye de los análisis de gravedad. La gravedad se construye a partir del código de lesividad (14 ileso; 1, 5, 6 y 7 leve; 2 moderado; 3 grave; 4 mortal, es decir, fallecido en las 24 horas siguientes).
- **Alcohol y droga:** el alcohol es positivo, negativo o sin dato. En droga solo aparece el valor 1 (891 positivos), por lo que el nulo se interpreta como «no positivo o sin prueba».
- **Meteorología:** los días sin precipitación o temperatura se excluyen de los análisis diarios (unos 110 días, el 5 %). Faltan datos de viento en aproximadamente el 25 % de las filas, por lo que el viento no se utiliza.

5. Análisis descriptivo

5.1 Volumen y tendencia

Entre 2019 y 2024 se registran **115.640 accidentes con víctimas**, una media de 52,8 al día. La pandemia explica el mínimo de 2020: 14.172 accidentes, un 35 % menos que en 2019 (21.934); en abril de 2020, durante el confinamiento, solo hubo 258 frente a 802 en marzo. Desde 2022 la cifra se estabiliza entre 20.200 y 20.700 al año, un 6 % por debajo de 2019. Los fallecidos a 24 horas son 173 en el periodo (entre 22 y 34 al año). En 2020 y 2021 el porcentaje de lesiones graves o mortales fue algo mayor (2,5-2,6 % frente al 1,9-2,3 % del resto de años), probablemente porque bajaron más los accidentes leves que los graves.



Figura 1. Accidentes con víctimas por año. Fuente: Ayuntamiento de Madrid; elaboración propia.

Por meses, octubre es el que concentra más accidentes (11.365 en los seis años) y agosto el que menos (6.494), con una caída estival que se repite todos los años. La Figura 2 muestra además el desplome de la primavera de 2020.

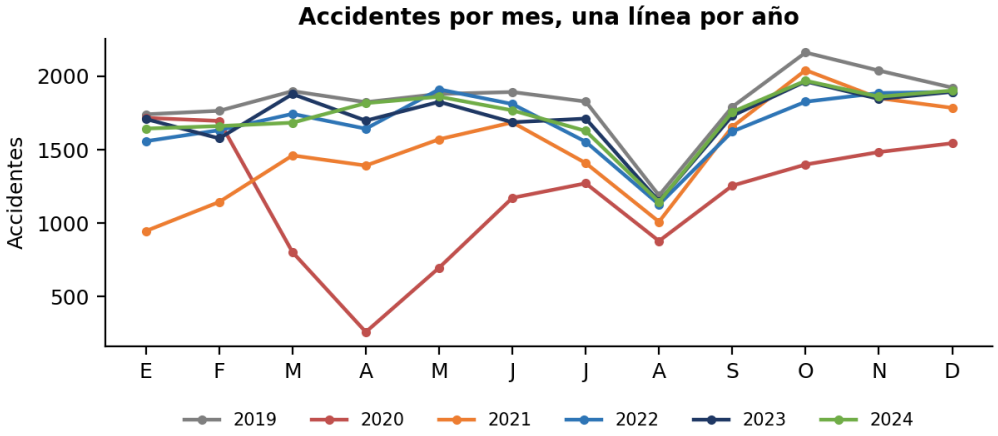


Figura 2. Accidentes por mes, una línea por año. Elaboración propia.

5.2 Patrón semanal y horario

Los accidentes se concentran a las 14 h y entre las 18 y las 19 h (unos 7.700 en cada una de esas horas), y son mínimos de madrugada (alrededor de 1.200-1.400 entre las 3 y las 5 h). El viernes es el día más accidentado (mediana de 65 al día), seguido de jueves (58) y martes (57); el sábado baja a 48 y el domingo a 42.

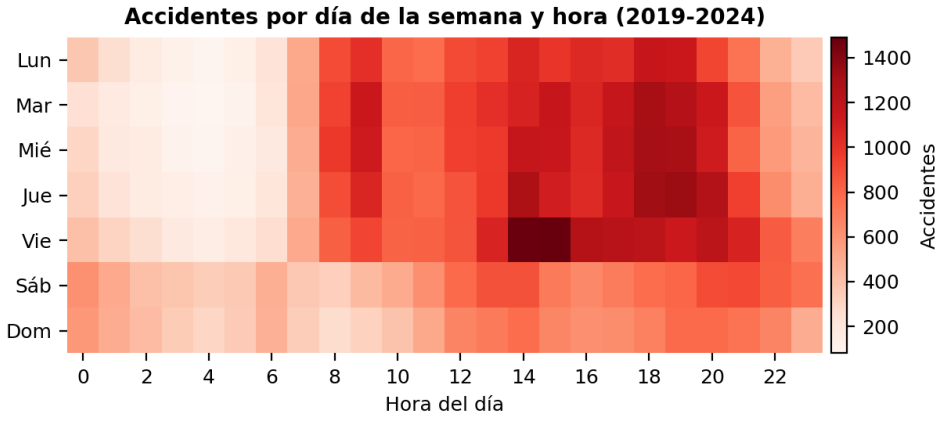


Figura 3. Mapa de calor de accidentes por día de la semana y hora. Elaboración propia.

5.3 Distritos

Puente de Vallecas (8.539), Salamanca (8.502) y Chamartín (7.977) son los distritos con más accidentes. El porcentaje de personas con lesión grave o mortal es parecido en todos ellos (entre el 1,6 % y el 2,5 % de las personas con lesividad conocida), por lo que las diferencias entre distritos están más en el volumen que en la gravedad. Cuatro accidentes no tienen distrito registrado.

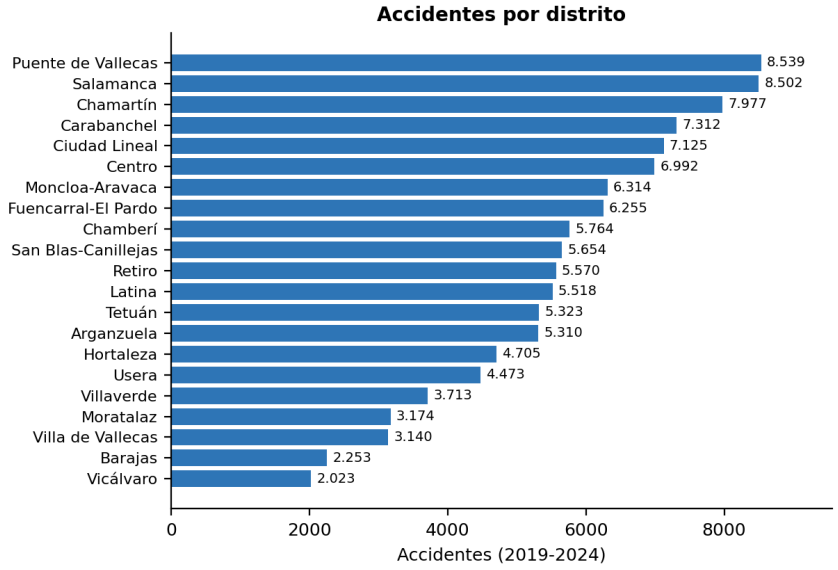


Figura 4. Accidentes por distrito (2019-2024). Elaboración propia.

5.4 Gravedad y tipo de vehículo

De las personas con lesividad conocida, el 2,2 % sufre una lesión grave o mortal. La gravedad depende mucho del vehículo: en motocicleta es del 6,2 % frente al 1,4 % del resto, y las motos de más de 125 cc (7,7 %), las de hasta 125 cc (5,2 %) y la bicicleta (4,2 %) están muy por encima del turismo (1,1 %).

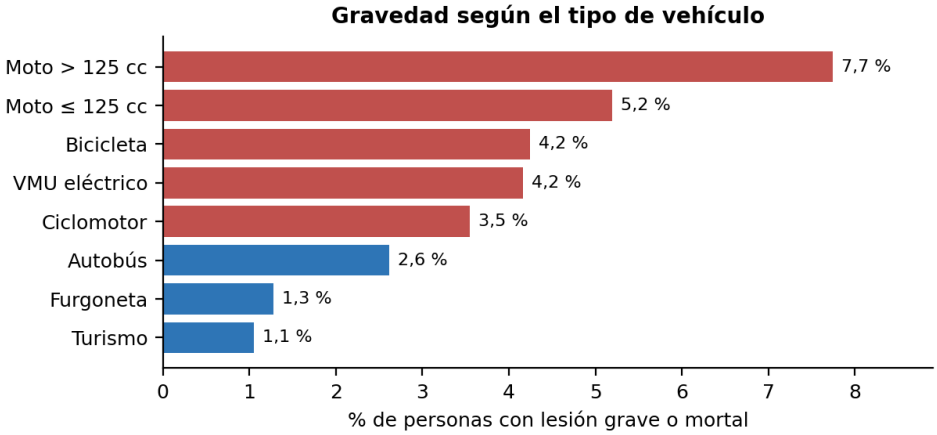


Figura 5. Porcentaje de personas con lesión grave o mortal por tipo de vehículo (lesividad conocida). Elaboración propia.

6. Análisis estadístico

La tabla resume las cinco hipótesis. Las pruebas no paramétricas se usan para los recuentos diarios, que no son normales; en los modelos de conteo y de regresión logística se controla por calendario y, en H5, por accidente (errores robustos con agrupación por *num_expediente*, porque las personas de un mismo accidente no son independientes).

	Resultado	Tamaño del efecto	Lectura práctica
H1 Lluvia y gravedad	$\chi^2 = 19{,}8$; gl = 4; p = 0,0005. Graves o mortales: 2,27 % sin lluvia (IC 95 % 2,18-2,35) y 2,09 % con lluvia (1,94-2,26).	V de Cramér = 0,012 (despreciable)	Significativa por el tamaño de muestra, pero sin relevancia práctica: la lluvia no cambia la gravedad.
H2 Accidentes por día, lluvia	Medianas 57 y 52 (425 y 1.657 días); U de Mann-Whitney p < 0,001. Binomial negativa: IRR = 1,046 (IC 95 % 1,021-1,073; p = 0,0003).	Rank-biserial = −0,13 (pequeño)	Los días de lluvia tienen alrededor de un 4,6 % más de accidentes.
H3 Día de la semana	Kruskal-Wallis H = 289,6; p < 0,001. Post-hoc con Bonferroni: el domingo se separa de todos los días laborables y el sábado de varios.	$\varepsilon^2 = 0{,}137$ (moderado)	El fin de semana, sobre todo el domingo, hay menos accidentes; el viernes, más.
H4 Temperatura y precipitación	Spearman: temperatura ρ = −0,164; precipitación ρ = 0,092 (ambas p < 0,001). Con mes y año en el modelo, la temperatura da IRR = 1,0042 por °C (IC 95 % 1,0009-1,0075; p = 0,011).	|ρ| < 0,2 (débil)	La relación bruta con la temperatura es sobre todo estacional; el efecto propio es de unos +4 % cada 10 °C.
H5 Factores de gravedad	Regresión logística con conductores (n = 106.109; pseudo $R^2 = 0{,}16$). Moto > 125 cc OR = 25,1; moto ≤ 125 cc OR = 16,8; bicicleta OR = 14,2; madrugada OR = 2,2; alcohol OR = 1,34; mujer OR = 0,73; lluvia OR = 0,88 (p = 0,03).	OR con IC 95 % (ver Figura 7)	El vehículo domina. La lluvia no aumenta la gravedad.

6.1 Frecuencia: lluvia, tipo de día y temperatura (H2-H4)

La Figura 6 compara las medias diarias. Con lluvia hay unos 55 accidentes al día frente a 52 sin ella, mientras que la diferencia por tipo de día es mucho mayor: unos 57 en un día laborable, 45 en un fin de semana no festivo y 36 en un festivo. En el modelo de binomial negativa, que controla a la vez día de la semana, festivo, año y mes, el efecto de la lluvia se mantiene (+4,6 %) y el del festivo es el más claro (IRR = 0,62; IC 95 % 0,58-0,66). El parámetro de dispersión se estimó con los datos (α = 0,03); con el valor fijo inicial de 0,1 el intervalo de la lluvia era más ancho (IRR = 1,045; p = 0,025).

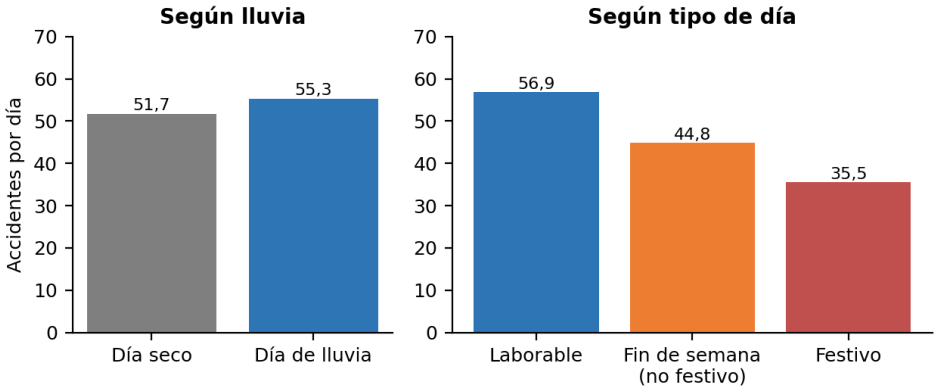


Figura 6. Accidentes medios por día según lluvia y tipo de día (2019-2024; días con dato meteorológico). Elaboración propia.

6.2 Gravedad: regresión logística (H5)

El modelo principal se limita a conductores, porque la prueba de alcohol se realiza sobre todo a ellos, y toma el turismo como categoría de referencia. En un primer modelo con todas las personas, el alcohol no mostraba asociación (OR = 1,06; p = 0,58). Una explicación plausible es la selección: entre las personas con lesividad conocida y prueba positiva, el 63,8 % no tuvo lesiones frente al 55,2 % de las negativas, de modo que los positivos se detectan con frecuencia en

conductores ilesos a los que se hace la prueba. Al restringir a conductores aparece el efecto esperado (OR = 1,34; IC 95 % 1,05-1,70). El resultado débil de la lluvia (OR = 0,88) no se interpreta como un efecto protector: es un contraste aislado entre muchos y su magnitud es pequeña.

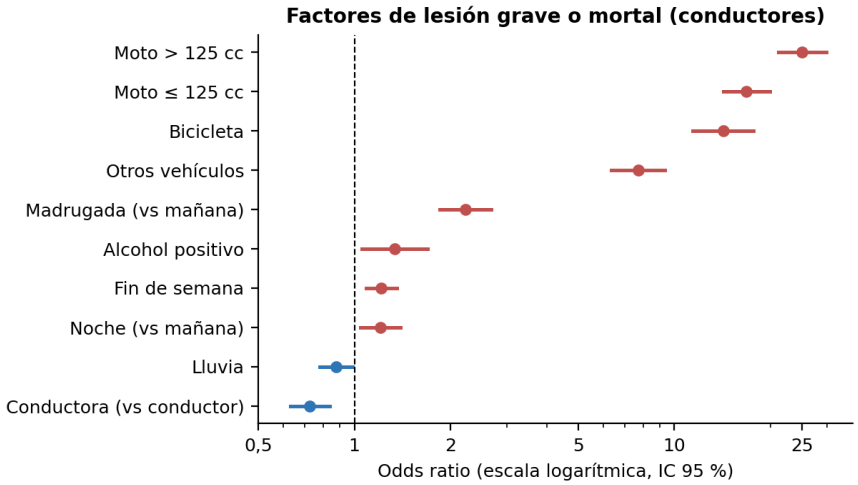
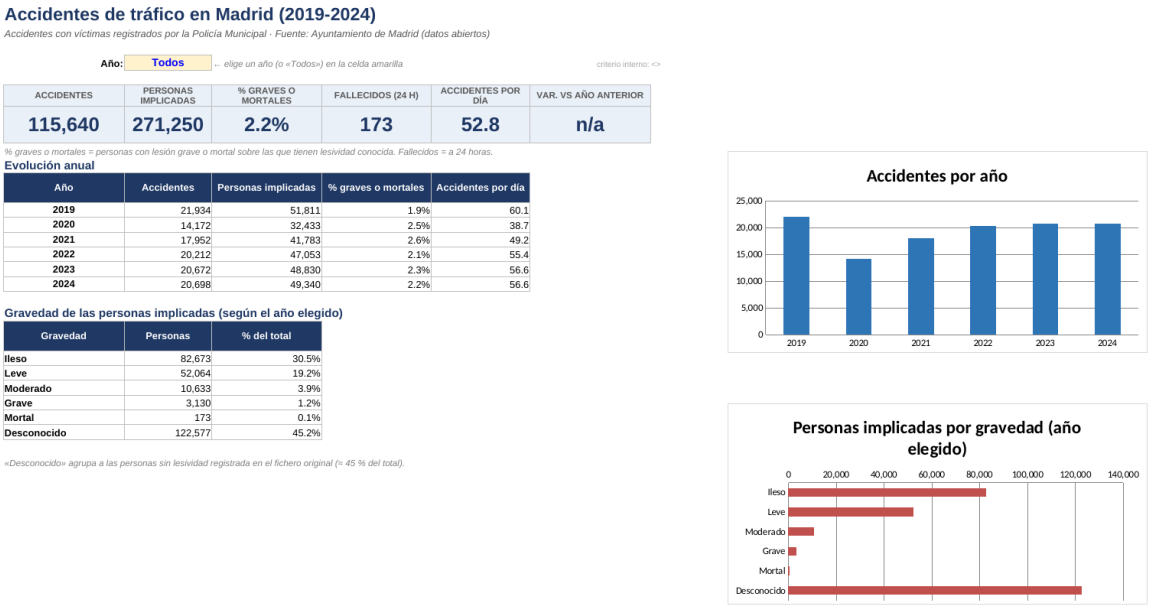


Figura 7. Odds ratio de lesión grave o mortal con IC 95 % (conductores; referencia: turismo, mañana y conductor). Rojo: aumenta el riesgo; azul: lo reduce; gris: el intervalo incluye 1. Elaboración propia a partir del modelo del notebook 03.

7. Dashboard en Excel

Los resultados descriptivos se han trasladado a un libro de Excel (*dashboard_accidentes_madrid.xlsx*) con cuatro hojas: **Resumen** (indicadores y evolución anual), **Temporal** (mapa de calor día × hora, estaciones y meses), **Distritos** y **Meteorología** (día seco frente a lluvia, intensidad y temperatura). Cada hoja principal tiene un filtro de año (celda amarilla) que actualiza tablas y gráficos mediante fórmulas (SUMIFS, COUNTIFS, AVERAGEIFS) sobre tres tablas base calculadas con Python. Una hoja «Léeme» recoge las definiciones y las limitaciones. Las cifras del libro coinciden con las de los notebooks.



Accidentes de tráfico en Madrid (2019-2024)

Accidentes con víctimas registrados por la Policía Municipal · Fuente: Ayuntamiento de Madrid (datos abiertos)

Año: Todos ← elige un año (o «Todos») en la celda amarilla

ACCIDENTES	PERSONAS IMPLICADAS	% GRAVES O MORTALES	FALLECIDOS (24 H)	ACCIDENTES POR DÍA	VAR. VS AÑO ANTERIOR
115,640	271,250	2.2%	173	52.8	n/a

% graves o mortales = personas con lesión grave o mortal sobre las que tienen lesividad conocida. Fallecidos = a 24 horas.

Evolución anual

Año	Accidentes	Personas implicadas	% graves o mortales	Accidentes por día
2019	21,934	51,811	1.9%	60.1
2020	14,172	32,433	2.5%	38.7
2021	17,952	41,783	2.6%	49.2
2022	20,212	47,053	2.1%	55.4
2023	20,672	48,830	2.3%	56.6
2024	20,698	49,340	2.2%	56.6

Gravedad de las personas implicadas (según el año elegido)

Gravedad	Personas	% del total
Ileso	82,673	30.5%
Leve	52,064	19.2%
Moderado	10,633	3.9%
Grave	3,130	1.2%
Mortal	173	0.1%
Desconocido	122,577	45.2%

«Desconocido» agrupa a las personas sin lesividad registrada en el fichero original (≈ 45 % del total).

Figura 8. Hoja «Resumen» del dashboard de Excel.

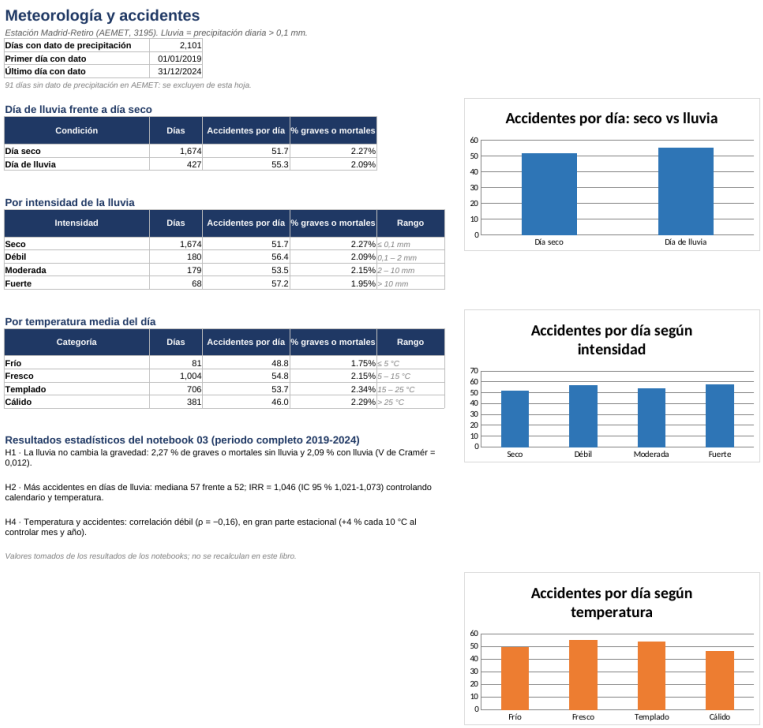


Figura 9. Hoja «Meteorología» del dashboard de Excel.

8. Limitaciones

- **Meteorología:** una sola estación (Retiro) para toda la ciudad y precipitación diaria, que no capta si llovía en el momento del accidente. Esto tiende a diluir el efecto de la lluvia. Faltan datos de viento en aproximadamente el 25 % de las filas.
- **Población:** solo accidentes con víctimas registrados por la Policía Municipal, y sin datos de exposición (volumen de tráfico), por lo que se analizan recuentos y proporciones, no riesgos por kilómetro recorrido.
- **Lesividad:** alrededor del 45 % de las personas no tiene lesividad registrada. Si esa ausencia no es aleatoria, los resultados de gravedad pueden estar sesgados.
- **Alcohol:** la prueba no se hace a todos los implicados (sesgo de selección), por lo que se interpreta solo en conductores y con cautela.
- **Dependencia entre observaciones:** las personas de un accidente no son independientes. La regresión logística lo corrige con errores robustos, pero el chi-cuadrado de H1 no.
- **Días excluidos:** unos 110 días (5 %) sin dato de lluvia o temperatura quedan fuera de los análisis diarios.
- **Inferencia:** son asociaciones observacionales, no relaciones causales, y se han contrastado varias hipótesis sin corrección global, de modo que los resultados con p cercana a 0,05 deben leerse con prudencia.

9. Conclusiones y próximos pasos

Conclusiones. La meteorología influye poco en la accidentalidad de Madrid. La lluvia aumenta ligeramente el número de accidentes (+4,6 %), pero no su gravedad, y la temperatura apenas añade información una vez descontada la estacionalidad. Pesan mucho más el calendario (viernes, fines de semana y festivos), la franja horaria y, sobre todo, el tipo de vehículo: las motos y las bicicletas presentan una probabilidad de lesión grave o mortal entre 14 y 25 veces superior a la del turismo. Para la gestión de la seguridad vial, esto sugiere poner el foco en los usuarios vulnerables y en las franjas de madrugada y fin de semana más que en la meteorología.

Próximos pasos.

- Incorporar más estaciones de AEMET o datos horarios de precipitación para captar la lluvia en el momento del accidente.
- Añadir datos de intensidad de tráfico del Ayuntamiento para analizar el riesgo y no solo el recuento.
- Explorar el análisis espacial con las coordenadas UTM (puntos negros por calle y distrito).
- Estudiar la interacción entre lluvia y franja horaria y entre lluvia y tipo de vehículo.

Anexo. Tecnologías y reproducibilidad

Tecnologías: Python (pandas, SciPy, statsmodels, seaborn y matplotlib), notebooks en Visual Studio Code y Excel para el dashboard.

Repositorio: github.com/miguelffer12/proyecto-final-aemet. Contiene *data/raw* (datos en bruto), *notebooks* (01 limpieza, 02 descriptivo, 03 estadístico), *src* (módulos de limpieza, variables y estadística), *dashboard* (libro de Excel) y *reports* (informe y figuras). El dataset final se regenera ejecutando los notebooks en orden; en el repositorio se incluye comprimido.

Fuentes: Ayuntamiento de Madrid, portal de datos abiertos (datos.madrid.es), «Accidentes de tráfico de la ciudad de Madrid». AEMET OpenData (opendata.aemet.es), climatología diaria; se cita a AEMET como autora de la información.